

Sistemas Lineales

Análisis de error

Prof.: Dra. Nélida Beatriz Brignole

Errores

- Errores de redondeo
- Errores en los valores de A y b
- Incertidumbre en la solución calculada x

Residuo

$$Ax_* = b$$

$$e = x_* - A^{-1}b$$

$$r(x) = b - Ax$$

$$r(x) = 0 \quad \Rightarrow \quad x = A^{-1}b$$

$$\|r(x)\| \text{ es medida de } \|e(x)\| = \|x - x_*\|$$

Sistema mal condicionado

$$A = \begin{bmatrix} 1.2969 & 0.8648 \\ 0.2161 & 0.1441 \end{bmatrix} \quad b = \begin{bmatrix} 0.8642 \\ 0.1440 \end{bmatrix} \quad x = \begin{bmatrix} 0.9911 \\ -0.4870 \end{bmatrix}$$

$$r = \begin{bmatrix} -10^{-8} \\ 10^{-8} \end{bmatrix} \quad \text{sin embargo el V.V. es : } x_* = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

$\|r\|$ pequeño $\|e\|$ grande

$$\begin{bmatrix} 1.2969 & 0.8648 & 0.8642 \\ 0 & 0.1441 - \underbrace{\frac{0.2161}{1.2969} 0.8648}_{0.1440999923} & X \end{bmatrix}$$

$$\det A = 0.1868832 - 0.1868832 = 0$$

Relación entre residuo y error

$$Ax_* = b$$

$$Ax - Ax_* = Ax - b$$

$$A(x - x_*) = -r(x)$$

$$A e(x) = -r(x)$$

$$e(x) = -A^{-1}r(x)$$

$$\|e(x)\| = \|A^{-1}r(x)\| \leq \|A^{-1}\| \|r(x)\|$$

Relación entre residuo y error

$$\|e(x)\| \leq \|A^{-1}\| \|r(x)\|$$

$$\frac{\|e(x)\|}{\|x_*\|} \leq \|A^{-1}\| \frac{\|r(x)\|}{\|x_*\|}$$

$$\|Ax_*\| = \|b\| \leq \|A\| \|x_*\| \quad \Rightarrow \quad \frac{1}{\|x_*\|} \leq \frac{\|A\|}{\|b\|}$$

$$\frac{\|e(x)\|}{\|x_*\|} \leq \|A^{-1}\| \frac{\|r(x)\|}{\|x_*\|} \leq \frac{\|A\|}{\|b\|} \|A^{-1}\| \|r(x)\| = K(A) \frac{\|r(x)\|}{\|b\|}$$

Número de condición

$$K(A) = \|A\| \|A^{-1}\| \geq \|AA^{-1}\| = \|I\| \geq \rho(I) = 1$$

$$\Rightarrow K(A) \geq 1$$

$$K(A) = \|A\| \|A^{-1}\| \geq \rho(A) \rho(A^{-1}) \quad \text{porque} \quad \rho(A) \leq \|A\|$$

$$\rho(A^{-1}) \leq \|A^{-1}\|$$

$$\rho(A) \rho(A^{-1}) \leq \|A\| \|A^{-1}\|$$

$$K(A) \geq \frac{\max_{1 \leq i \leq n} |\lambda_i|}{\min_{1 \leq i \leq n} |\lambda_i|} \quad \text{porque}$$

$$K(A) \geq \rho(A) \rho(A^{-1}) = \max_{1 \leq i \leq n} |\lambda_i| \frac{1}{\min_{1 \leq i \leq n} |\lambda_i|}$$

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \quad \text{y} \quad \rho(A^{-1}) = \frac{1}{\min_{1 \leq i \leq n} |\lambda_i|}$$

Cotas de error

$$A(x_* + \delta x) = b + \delta b$$

$$A \delta x = \delta b$$

$$\delta x = A^{-1} \delta b$$

$$\|\delta x\| \leq \|A^{-1}\| \|\delta b\| \quad (\text{consistencia})$$

$$\frac{\|\delta x\|}{\|x_*\|} \leq \|A^{-1}\| \frac{\|\delta b\|}{\|x_*\|}$$

$$\|A^{-1}\| \frac{\|\delta b\|}{\|x_*\|} = \|A^{-1}\| \frac{\|A\|}{\|A\|} \frac{\|\delta b\|}{\|x_*\|} \leq \underbrace{\|A^{-1}\| \|A\|}_{K(A)} \frac{\|\delta b\|}{\|b\|}$$

Cotas de error

$$(A + \delta A)(x_* + \delta x) = b$$

$$A\delta x + \delta Ax_* + \delta A\delta x = 0$$

$$A\delta x + \delta A(x_* + \delta x) = 0$$

$$\delta x = A^{-1}\delta A(x_* + \delta x)$$

$$\|\delta x\| = \|A^{-1}\delta A(x_* + \delta x)\| \leq \|A^{-1}\delta A\| \|x_* + \delta x\|$$

$$\frac{\|\delta x\|}{\|x_* + \delta x\|} \leq \|A^{-1}\delta A\| \leq \|A^{-1}\| \|\delta A\| \frac{\|A\|}{\|A\|}$$

$$\frac{\|\delta x\|}{\|x_* + \delta x\|} \leq K(A) \frac{\|\delta A\|}{\|A\|}$$

Resolución de Sistemas Lineales

Métodos directos:

Refinamiento iterativo

Refinamiento iterativo

$$r = b - A\bar{x}$$

$$r = Ax - A\bar{x} = A(x - \bar{x})$$

$$A\delta x = r$$

Algoritmo: Refinamiento Iterativo

Dado: x_0 solución aproximada de $Ax = b$

1) Calcular en doble precisión $r_0 = b - Ax_0$

2) para $i = 1$ hasta convergencia hacer :

a) Resolver por descomposición LU $A\delta x_{i-1} = r_{i-1}$

b) $x_i = x_{i-1} - \delta x_{i-1}$

c) Calcular en doble precisión $r_i = b - Ax_i$

d) Test de convergencia

Si $\|r_i\| > \|r_{i-1}\| \Rightarrow \text{PARAR (no se puede refinar más)}$

Si $\frac{\|r_i\|}{\|b\|} > \varepsilon \Rightarrow \text{PARAR (} x_i \text{ es la solución)}$

Si $i \geq \max it \Rightarrow \text{PARAR (no se alcanzó el error deseado)}$

fin lazo

Resolución de Sistemas Lineales

Métodos iterativos

$$x_{k+1} = \varphi(x_k)$$

Métodos iterativos

- **Ventajas?**

- **Espacio:** convenientes para matrices ralas (sparse)
- **Tiempo:** menor número de operaciones

- **Desventajas?**

- **Velocidad:** convergencia lenta
- **Convergencia:** no siempre se obtiene la solución en un número finito de pasos

Diseño general

$$Ax = b$$

$$(B + C)x = b$$

$$Bx + Cx = b$$

$$x = B^{-1}b - B^{-1}Cx$$

$$x_{k+1} = B^{-1}b - B^{-1}Cx_k$$

Cuándo tiene sentido esto?

$$\lim_{k \rightarrow \infty} x_k = x_*$$

$$x_* = B^{-1}b - B^{-1}Cx_*$$

$$x_{k+1} = B^{-1}b - B^{-1}Cx_k$$

$$x_{k+1} - x_* = -B^{-1}C(x_k - x_*)$$

$$e_{k+1} = -B^{-1}C e_k$$

Análisis de error

$$\|e_{k+1}\| = \|B^{-1}Ce_k\| \leq \|B^{-1}C\| \|e_k\|$$

$$\|e_{k+1}\| \leq \|B^{-1}C\|^2 \|e_{k-1}\| \leq \dots \leq \|B^{-1}C\|^{k+1} \|e_0\|$$

condición suficiente de convergencia :

$$\|B^{-1}C\| < 1$$

Condición necesaria y suficiente de convergencia

$$x_{k+1} = Mx_k + b$$

$$\rho(M) < 1$$

$$x_{k+1} - x_* = M^{k+1}(x_0 - x_*)$$

Demostración

$$x_0 - x_* = \alpha_1 u_1 + \alpha_2 u_2 + \dots + \alpha_n u_n$$

$$x_1 - x_* = M(\alpha_1 u_1 + \alpha_2 u_2 + \dots + \alpha_n u_n)$$

$$x_1 - x_* = \alpha_1 M u_1 + \alpha_2 M u_2 + \dots + \alpha_n M u_n$$

$$x_1 - x_* = \alpha_1 \lambda_1 u_1 + \alpha_2 \lambda_2 u_2 + \dots + \alpha_n \lambda_n u_n$$

$$x_2 - x_* = M(x_1 - x_*) = \alpha_1 \lambda_1 M u_1 + \alpha_2 \lambda_2 M u_2 + \dots + \alpha_n \lambda_n M u_n$$

$$\underbrace{x_k - x_*}_{\rightarrow 0} = \alpha_1 \lambda_1^k u_1 + \alpha_2 \lambda_2^k u_2 + \dots + \alpha_n \lambda_n^k u_n$$

$$\Leftrightarrow |\lambda_i| < 1 \quad \forall i \quad \Rightarrow \max_{1 \leq i \leq n} |\lambda_i| < 1$$

$$\Rightarrow \rho(M) < 1$$

Principales Métodos Iterativos

- **Jacobi**
- **Gauss Seidel**
- **SOR: Sobrerelajación sucesiva**

Métodos Iterativos: Jacobi

$$\begin{aligned}x_1^{(k+1)} &= \frac{b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)}}{a_{11}} & P_1 \\x_2^{(k+1)} &= \frac{b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)}}{a_{22}} & P_2 \\&\vdots \\x_n^{(k+1)} &= \frac{b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \dots - a_{nn-1}x_{n-1}^{(k)}}{a_{nn}} & P_n\end{aligned}$$

Métodos Iterativos: Gauss Seidel

$$x_1^{(k+1)} = \frac{b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)}}{a_{11}}$$

$$x_2^{(k+1)} = \frac{b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)}}{a_{22}}$$

\vdots

$$x_n^{(k+1)} = \frac{b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{nn-1}x_{n-1}^{(k)}}{a_{nn}}$$

Método de Jacobi

$$A = L + D + U$$

$$Ax = b$$

$$(L + D + U)x = b$$

$$Dx_{k+1} = -(L + U)x_k + b$$

$$x_{k+1} = \underbrace{-D^{-1}(L + U)}_{M_J} x_k + D^{-1}b$$

Método de Gauss Seidel

$$A = L + D + U$$

$$Ax = b$$

$$(L + D + U)x = b$$

$$(L + D)x_{k+1} = -Ux_k + b$$

$$x_{k+1} = \underbrace{-(L + D)^{-1}U}_{M_{GS}} x_k + (L + D)^{-1}b$$

Condiciones de convergencia

- Si A es simétrica, definida positiva, entonces Gauss-Seidel converge
- Si A es estrictamente diagonal dominante por filas, entonces Gauss-Seidel y Jacobi convergen

Diagonal dominancia

Def : se dice que $A \in \mathbb{R}^{n \times n}$ es diagonal dominante por filas si

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ i \neq j}}^n |a_{ij}| \quad \forall i = 1, n$$

Def : se dice que $A \in \mathbb{R}^{n \times n}$ es diagonal dominante por columnas si

$$|a_{jj}| \geq \sum_{\substack{i=1 \\ i \neq j}}^n |a_{ij}| \quad \forall i = 1, n$$

Diagonal dominancia estricta

Def : se dice que $A \in \mathbb{R}^{n \times n}$ es estrictamente diagonal dominante por filas si

$$|a_{ii}| > \sum_{\substack{j=1 \\ i \neq j}}^n |a_{ij}| \quad \forall i = 1, n$$

Def : se dice que $A \in \mathbb{R}^{n \times n}$ es estrictamente diagonal dominante por columnas si

$$|a_{jj}| > \sum_{\substack{i=1 \\ i \neq j}}^n |a_{ij}| \quad \forall i = 1, n$$

Teorema

- Si A es estrictamente diagonal dominante por filas , entonces A puede ser factorizada usando EG sin pivoteo por columnas
- Si A es estrictamente diagonal dominante por columnas , entonces A puede ser factorizada usando EG sin pivoteo por filas

Método SOR

$$p_{GS} = x_{k+1}^{GS} - x_k$$

$$Dx_{k+1}^{GS} = b - Lx_{k+1} - Ux_k$$

$$x_{k+1} = x_k + \underbrace{wp_{GS}}_{\text{pasoSOR}} \quad w > 1 \text{ (aceleración - amplificación)}$$

$$x_{k+1} = x_k + wx_{k+1}^{GS} - wx_k = \overbrace{(1-w)}^{\uparrow} x_k + wx_{k+1}^{GS}$$

$$wDx_{k+1}^{GS} = Dx_{k+1} - D(1-w)x_k$$

$$w(b - Lx_{k+1} - Ux_k) = Dx_{k+1} - D(1-w)x_k$$

$$wb - wUx_k + D(1-w)x_k = Dx_{k+1} + wLx_{k+1}$$

$$x_{k+1} = \underbrace{(D + wL)^{-1}[-wU + D(1-w)]}_{M_{SOR}} x_k + w(D + wL)^{-1}b$$

Condición necesaria de convergencia

$$0 < w < 2$$

Observaciones

- $w=1$ Método de Gauss-Seidel
- $w<1$ Subrelajación
(paso más corto que el de GS)
- $w>1$ Sobrerelajación
(paso más largo que el de GS)

Bibliografía sugerida

- Rao “Applied Numerical Methods for Engineers and Scientists”, Prentice Hall, 2002
- Págs 152-188